

Constructing and Analyzing a Standardized IT Recruitment Dataset via LLM-Assisted Extraction and Statistical Imputation

ĐÌNH HOÀNG PHONG & NGUYỄN ĐÌNH TUẤN PHÚC

University of Information Technology, VNU-HCM

GVHD: TS. Nguyễn Gia Tuấn Anh

CN. Trần Quốc Khánh



Problem Statement



Các nền tảng tuyển dụng như ITviec và TopDev chứa lượng lớn thông tin giá trị về:

- Kỹ năng công nghệ
- Kinh nghiệm làm việc
- Yêu cầu ngoại ngữ
- Mức lương



✗ DỮ LIỆU TỒN TẠI DƯỚI DẠNG VĂN BẢN TỰ DO

✗ KHÓ PHÂN TÍCH TỰ ĐỘNG

✗ THIẾU CHUẨN HÓA

✗ NHIỀU TRƯỜNG THÔNG TIN BỊ THIẾU



Job description

Phân tích dữ liệu chuyên sâu, xây dựng mô hình dự đoán và cung cấp insights chiến lược cho các business units trong hệ sinh thái Galaxy Holdings. Biến dữ liệu thành giá trị kinh doanh thực tế.

TRÁCH NHIỆM CHÍNH

Phân tích dữ liệu khách hàng cross-platform (Galaxy Pay, Galaxy Joy, Galaxy One) để xây dựng Customer 360 view; Xây dựng mô hình dự đoán: Customer Churn Prediction, Customer Lifetime Value (CLV), Next Best Action

Phát triển Attribution Model, Marketing Mix Model để tối ưu ROI của các chiến dịch marketing; Xây dựng A/B Testing framework và Statistical Analysis cho product experiments

Phân tích Transaction Data để phát hiện patterns, anomalies và cơ hội cross-sell/upsell; Xây dựng Dashboard và automated reporting sử dụng BI tools (Tableau/PowerBI/Looker)

Trình bày insights và recommendations cho Business Leaders, hỗ trợ data-driven decision making Collaborate với Data Engineers để define data requirements và với ML Engineers để productionize models

Your skills and experience

YÊU CẦU BẮT BUỘC

Tối thiểu 5 năm kinh nghiệm Data Science/Analytics trong môi trường doanh nghiệp; Thành thạo Python (Pandas, NumPy, Scikit-learn, StatsModels) và SQL

Kiến thức vững về Statistics: Hypothesis Testing, Regression, Bayesian Methods, Causal Inference; Kinh nghiệm với BI/Visualization tools: Tableau, PowerBI, Looker hoặc tương đương

Kinh nghiệm xây dựng và đánh giá ML models: Classification, Regression, Clustering, Time Series; Kỹ năng storytelling với data, trình bày kết quả phân tích cho non-technical stakeholders

Kinh nghiệm với A/B Testing, Experimental Design và Statistical Significance assessment; Bằng Thạc sĩ về Statistics, Mathematics, Computer Science, Economics hoặc lĩnh vực định lượng

ƯU TIÊN / LỢI THẾ

Kinh nghiệm trong Fintech/E-commerce/Digital Platform

Hiểu biết về Product Analytics (Amplitude, Mixpanel) và Growth Metrics

Kinh nghiệm với Causal Inference methods (Diff-in-Diff, RDD, Instrumental Variables)

Job_Title	Job Domain	Company	Location	Min years of exp	Language Requirement	Skills	Link	JD & Requirements	Salary_Min_VND	Salary_Max_VND
Data Scientist	Data & AI	GALAXY HOLDINGS	Ho Chi Minh	5		Python, SQL, Machine Learning, Data Analysis, Data Visualization, Deep Learning	https://itviec.com/it-jobs/senior-data-scientist-python-tableau-powerbi-galaxy-holdings-3510?job_feature=pro	Job description Phân tích dữ liệu chuyên sâu, xây dựng mô hình dự đoán và cung cấp insights chiến lược cho các business units trong	25000000	50000000

Proposed Pipeline



Raw Data Acquisition

250 mẫu được chia thành:

- **100** mẫu gán nhãn thủ công
- **150** mẫu dành cho LLM

Thuộc tính được gán nhãn:

1. *Job Domain*
2. *Min years of Experience*
3. *Language Requirement*
4. *Skills*

Bước 1

Thu thập dữ liệu thô

Bước 2

Gán 100 nhãn độc lập

Bước 3

Xác minh độ tương đồng

Bước 4

Giải quyết xung đột

Ground Truth Construction

LLM-Assisted Information Extraction

Trích xuất thông tin bằng LLM

- Gemini 3.1 Flash Lite
- Temperature = 0.0

Khung định nghĩa chặt chẽ

- Chỉ trích xuất kỹ năng trong danh sách cho phép
- Quy tắc rõ ràng cho các danh mục để nhầm lẫn
- Yêu cầu đầu ra theo định dạng JSON chuẩn



SYSTEM PROMPT: EXPERT IT RECRUITER (VIETNAM)



YOUR TASK

Read JD and extract key information in **EXACT JSON** format.

1



Job_Domain

Select **EXACTLY 1** from {DOMAINS}.

2



Min_years_of_exp

Extract minimum years of experience.

3



Language_Requirement

- Select **EXACTLY 1** from {LANGUAGES}.
- **PRIORITY:** If multiple languages required → pick the more niche/specific one.
- If no language mentioned → "None".

4



Skills

- Extract key skills.
- Filter: **ONLY ALWAYS ALLOWED** keywords.
- Absorb to standard tools if needed.

STRICT DEFINITIONS (NO LABEL INFLATION)



Business Analysis
ONLY for elicitation
or writing
(BRD/SRS).



System Design
ONLY for designing
architecture or
distributed systems.



Monitoring
ONLY for operating
automated monitoring
systems.



Data Analysis
ONLY when using
data to extract
business insights.



Manual Test
ONLY for QA/QC
roles designing
test cases.



OUTPUT FORMAT (EXACT JSON)

```
{  
  "Job_Domain": "string",  
  "Min_years_of_exp": number | null,  
  "Language_Requirement": "string",  
  "Skills": ["string", "string", ...]  
}
```

Ground Truth Validation

Skills (Jaccard Similarity)

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

Categorical (Cohen's Kappa)

$$\kappa = \frac{p_o - p_e}{1 - p_e}$$

Thuộc tính	Điểm số
Job Domain	0.937
Experience	0.837
Language Requirement	0.840
Skills (Jaccard)	76.35%

LLM Performance Evaluation

Data Cleaning, Standardization & Basic Imputation



Chuẩn hóa Địa lý

Ánh xạ văn bản tự do về danh mục 63 tỉnh thành chuẩn. Xử lý tự động các từ viết tắt và lọc bỏ nhiều từ tên đường trùng lặp (VD: Đường Điện Biên Phủ).



Điền khuyết kinh nghiệm

Điền các giá trị thiếu (NaN) của yêu cầu số năm kinh nghiệm bằng giá trị trung vị dựa trên từng lĩnh vực công việc tương ứng.



Đổi Tiền tệ

Sử dụng Regex trích xuất cận trên/dưới. Đổi USD sang VND và tự động quy đổi lương theo năm/tháng, cũng như xử lý các đơn vị viết tắt như "triệu" hay "mil".



Xử lý Lỗi Logic

Phát hiện và loại bỏ các bản ghi có lỗi nhập liệu từ nhà tuyển dụng.

VD: Lương Tối thiểu > Lương Tối đa.

Salary Imputation

Giải pháp: Experience-Aware Salary Imputation



1. Xử lý giá trị ngoại lai

Các mức lương cao bất thường vượt quá phân vị **thứ 80** trong từng lĩnh vực bị loại khỏi nhóm tham chiếu.



2. Láng giếng gần nhất

Tìm các bản ghi tham chiếu thuộc **cùng lĩnh vực** và có mức chênh lệch **± 1 năm kinh nghiệm**.



3. Ưu tiên trung vị

Dùng Median thay vì Mean để lấy giá trị đại diện. Điều này giúp giữ tính ổn định với các mẫu nhỏ ($N < 3$) và chống lại đặc tính lệch phải của lương CNTT.


75% JD không công khai lương

Loại Bỏ

Còn khoảng 60 mẫu

Mất phần lớn dữ liệu và gây sai lệch kết quả phân tích


Geographic Distribution of IT Jobs



Concentration of Jobs by location




Salary Benchmarks Across Domains



Thị trường phân hóa rõ rệt: Các vai trò định hướng dữ liệu và phần mềm bứt phá thu nhập, trong khi mảng Design và Testing duy trì mức bình ổn.

The Economic Value of Foreign Languages

Salary Distribution: Foreign Language vs. No Foreign Language



Dù mức lương phổ biến tương đương nhau, nhóm yêu cầu ngoại ngữ sở hữu dải lương rộng hơn hẳn với tiềm năng thu nhập có thể vươn tới mốc 100 triệu VNĐ.




Skill Demand & Co-occurrence

Kỹ năng hàng đầu theo Lĩnh vực

- **Data & AI:** Python (~68%) và SQL (~55%) là tiêu chuẩn bắt buộc.
- **Software Development:** API (~56%) dẫn đầu, nổi bật xu hướng DevOps hóa với CI/CD và Git (>40%).
- **Infrastructure:** Chuyên môn hóa cao, định hình bởi Security (~74%) và Monitoring (~70%).
- **Management & Analysis:** Business Analysis (~63%) là kỹ năng xương sống.
- **Testing & Quality:** Manual và Automation Test bám sát nhau, cùng vượt 75%.

Các tổ hợp công nghệ thường xuất hiện cùng nhau nhất:

- **Hệ sinh thái DevOps:** Gắn kết chặt chẽ nhất với CI/CD + AWS (44 cặp) và CI/CD + Docker (41 cặp).
- **Đa đám mây:** AWS + Azure (36 cặp), phản ánh nhu cầu linh hoạt nền tảng.
- **Kiến trúc & Vận hành:** Microservices + API (35 cặp) và Security + Monitoring (30 cặp).
- **Kỹ năng liên kết chéo:** API và SQL đóng vai trò "chất keo", kết hợp mạnh với hầu hết các nhóm khác.



Limitations

Quy mô & Phạm vi dữ liệu

Với 250 mẫu từ hai nền tảng chính (ITviec, TopDev), tập dữ liệu phục vụ tốt mục đích phân tích khám phá nhưng có thể chưa đại diện một cách tuyệt đối cho toàn bộ thị trường quốc gia hoặc các kênh tuyển dụng phi chính thức.

Hạn chế về dữ liệu lương

Do khoảng 75% mức lương được điền khuyết qua thuật toán Láng giềng Gần nhất, các cột mốc chuẩn mang theo sự không chắc chắn thống kê nội tại và đại diện cho các phân phối ước tính thay vì số liệu thực tế chính xác.

Bộ phân loại tĩnh

Danh sách 78 kỹ năng giúp chuẩn hóa quá trình trích xuất nhưng bị cứng nhắc. Nó có nguy cơ bỏ sót các công nghệ ngách mới nổi trừ khi được cập nhật định kỳ, và trích xuất LLM zero-shot vẫn có thể có sai sót biên.

Conclusion & Future Work

Kết luận

Nghiên cứu đã chuẩn hóa thành công dữ liệu web thô thành tập dữ liệu sẵn sàng để phân tích, thông qua một quy trình tiền xử lý có khả năng tái lập hoàn toàn.

Hướng phát triển tương lai

- Tự động hóa quy mô lớn: Triển khai kiến trúc prompt đã xác minh trên dữ liệu luồng (streaming) để theo dõi thay đổi thị trường theo thời gian thực.
- Mô hình dự đoán: Sử dụng tập dữ liệu đã làm sạch để huấn luyện mô hình hồi quy dự đoán lương cá nhân hóa dựa trên tổ hợp kỹ năng chuyên biệt.
- Bộ phân loại động: Tích hợp RAG (Retrieval-Augmented Generation) để tự động cập nhật danh sách kỹ năng khi có các framework mới xuất hiện.

Questions & Discussion

Thank you for your attention

Contact: 24521330@gm.uit.edu.vn | 24521384@gm.uit.edu.vn

University of Information Technology